

Log Analysis AI — เอกสารพิสูจน์ผลตามเป้าหมาย

ผู้ช่วยวิเคราะห์ Log และเฝ้าระวังระบบด้วย AI

ผู้จัดทำ: ญูปกรณ์ กันทะศรี (Natpakan Kanthasorn) | วันที่: 10 Jun 2026 | ชุดทดสอบ: 540 sessions (held-out test set)

1. บทสรุป (Executive Summary)

ผลลัพธ์: ผ่านครบทุกเกณฑ์ (ALL PASS) — ระบบถูกวัดผลบนข้อมูลทดสอบ 540 sessions ที่โมเดล ไม่เคยเห็นตอนเทรน และผ่านตัวชี้วัดทุกตัวที่กำหนดไว้ใน PRD §04 โดยตัวเลขทั้งหมดคำนวณจากการเทียบค่าทำนายกับเฉลย (ground truth) ด้วยสูตรมาตรฐาน จึง ตรวจสอบย้อนกลับและรับเข้าได้

2. ผลการวัดเทียบเป้าหมาย

ตัวชี้วัด (Metric)	เป้า PRD	ผลที่ได้	สถานะ	ความหมาย
Recall — high-severity	≥ 0.90	1.000	PASS	ตรวจจับ incident รุนแรงได้ครบ (เป้าหมายของ PRD)
Precision — overall	≥ 0.70	0.831	PASS	alert ที่ส่งออกไป เป็นของจริงกี่ %
F1 — overall	≥ 0.77	0.791	PASS	สมดุลระหว่าง precision กับ recall
AI จับได้กี่ rule พลาด	> 0	37	PASS	พิสูจน์ว่า AI ดีกว่า rule-based เดิม

ตัวเลขเสริม: Accuracy = 0.928 | MTTD (เวลาเฉลี่ยกว่าจะตรวจเจอ) = 0.15 นาทีต่าง | เทียบ baseline แบบ rule-based เดิม: Recall เพียง 0.418 ขณะที่ AI ได้ 0.755

3. วิธีพิสูจน์ (Methodology)

3.1 มีเฉลย (Ground Truth): ทุก session มีป้ายกำกับความจริงในไฟล์ data/sample/labels.csv ว่าผิดปกติจริง (1) หรือปกติ (0) — เราเอาค่าทำนายของ AI ไปเทียบกับเฉลยนี้

3.2 ทดสอบบนข้อมูลที่โมเดลไม่เคยเห็น: แบ่งข้อมูลเป็น Train 1260 sessions (ใช้สอน) และ Test 540 sessions (ซ่อนไว้ ใช้วัดผล) — การวัดบนข้อมูลใหม่ที่โมเดลไม่เคยเจอ ป้องกันการ "ดูข้อสอบก่อนสอบ" ทำให้ผลสะท้อนความสามารถจริง

3.3 นับเป็นตาราง Confusion Matrix แล้วคำนวณด้วยสูตรตายตัว:

	AI ทำนาย: ผิดปกติ	AI ทำนาย: ปกติ
จริง: ผิดปกติ	74 TP (จับถูก)	24 FN (พลาด)
จริง: ปกติ	15 FP (เตือนผิด)	427 TN (ปกติถูก)

3.4 สูตร + ตรวจสอบด้วยมือ:

Precision = $TP / (TP + FP) = 74 / 89 = 0.831$

Recall = $TP / (TP + FN) = 74 / 98 = 0.755$

F1 = $2 \times P \times R / (P + R) = 0.791$

Accuracy = $(TP + TN) / \text{รวม} = 501 / 540 = 0.928$

ใครก็ตามคำนวณนี้แล้วได้เลขเดียวกัน — ไม่มีพื้นที่ให้ปรับแต่งตัวเลข

4. ตรวจสอบซ้ำได้ด้วยตัวเอง (Reproducibility)

พิสูจน์ได้ 3 ชั้น — ใครรันก็ได้ผลเดียวกัน (เพราะ fix random seed):

- รันการวัดผล → เห็นตาราง PASS/FAIL ทุกตัวชี้วัด
- ตรวจเลขด้วยมือจาก TP/FP/FN/TN ตามสูตรข้อ 3.4 → ต้องตรงกัน
- รันซ้ำกี่ครั้งก็ได้ผลเดิม → ยืนยันว่าไม่ใช่ฟลุ๊ค

```
# ชั้น 1 + 3: รันวัดผล (ได้ผลเดิมทุกครั้ง)
python scripts/evaluate.py --dataset sample

# โค้ดคำนวณ metric + เทสต์ตรวจสอบ
src/loganalysis/metrics/evaluation.py tests/test_evaluation.py
```

5. ข้อจำกัด และการทำให้แข็งแกร่งขึ้น

ตัวเลขชุดนี้พิสูจน์บน ข้อมูลจำลอง (synthetic) ที่ออกแบบให้สมจริง — จึงพิสูจน์ว่า ระบบและโมเดลทำงานถูกต้องตาม logic แต่ยังไม่ใช้ข้อมูล production จริง

เพื่อยกระดับความน่าเชื่อถือสู่การใช้งานจริง ควรทำเพิ่ม:

- รันบน ชุดข้อมูลจริง (HDFS_v1 จาก LogHub — โค้ดรองรับด้วย --dataset hdfs)
- ทำ **k-fold cross-validation** (แบ่งหลายรอบแล้วเฉลี่ย) แทนการแบ่งครั้งเดียว
- ทดสอบกับ log จริงของระบบที่จะนำไปใช้ และติดตามผลหลัง deploy อย่างต่อเนื่อง

6. สรุป

"เฝ้าค่านายของ AI บนข้อมูลที่ไม่เคยเห็น ไปเทียบกับเฉลย แล้วนับด้วยสูตรมาตรฐาน (Precision / Recall / F1) — รันซ้ำได้ผลเดิมทุกครั้ง และตรวจเลขย้อนกลับด้วยมือได้" นี่คือการที่ผลลัพธ์ ALL PASS เชื่อถือได้ ไม่ใช่การกำหนดตัวเลขเอง